

Modelos de Regressão de Poisson Inflacionados em Zero

ME714 | ANÁLISE DE DADOS DISCRETOS
Profa. Dra. Hildete Prisco Pinheiro

Caroline da Silva Mangile 195539
Gabriela Inocente Yogi 141812
Rodrigo Resende Soares Rocha 186819
Wesley R. da Silva Satelis 188650

2 de julho de 2021

1 Introdução

Neste trabalho são expostos conceitos teóricos e práticos a respeito dos modelos de Poisson Inflacionados em Zero (ZIP), com uma aplicação utilizando um conjunto de dados real. O conjunto é formado por viagens de acampamento feitas por 250 grupos de pessoas à um parque nos Estados Unidos.

Foram feitas análises descritivas, diagnósticos de modelo, interpretações a respeito do problema e predição. Todo o trabalho foi conduzido com o uso da linguagem e ambiente de computação estatística R (R Core Team 2021).

2 Métodos

2.1 Distribuição de Poisson

A distribuição de Poisson é uma distribuição discreta de contagem das ocorrências de um evento em um determinado intervalo de tempo. Uma variável aleatória X segue uma distribuição de Poisson se sua função densidade de probabilidade é dada por

$$P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!},$$

em que $\lambda > 0$, representa a taxa de ocorrência por unidade média e é também a média e a variância da distribuição.

2.2 Teste de superdispersão

O teste de superdispersão proposto por Cameron e Trivedi (1990) é baseado em uma regressão linear sem o intercepto com as hipóteses

$$H_0 : Var(y_i) = \lambda_i \quad vs \quad H_1 : Var(y_i) = \lambda_i + \alpha g(\lambda_i)$$

em que α é um parâmetro desconhecido e $g(\cdot)$ é uma função definida, comumente $g(\lambda_i) = \lambda_i^2$ ou $g(\lambda_i) = \lambda_i$. Este teste é conduzido estimando-se o modelo de Poisson, construindo $\hat{\lambda}_i = \exp(\mathbf{x}'_i \hat{\beta})$ e ajustando um modelo por mínimos quadrados ordinários sem o intercepto

$$\frac{(y_i - \hat{\lambda}_i)^2 - y_i}{\hat{\lambda}_i} = \alpha \frac{g(\hat{\lambda}_i)}{\hat{\lambda}_i} + e_i$$

em que e_i é o erro. A significância do coeficiente α implica na existencia de superdispersão nos dados.

2.3 Modelos de Poisson Inflacionados em Zero (ZIP)

Uma propriedade importante da distribuição de Poisson é que a média e variância são iguais, $Var(y_i|x_i) = E(y_i|x_i) = \lambda_i$, esta propriedade é referida como equidispersão. Na prática a suposição de equidispersão é violada quando a variância das contagens observadas é maior que a média por conta de heterogeneidade não observada ou quando a frequência de zeros é maior que o número de zeros esperado em uma distribuição de Poisson.

Assumindo que a variável resposta tem distribuição de Poisson e que o logaritmo de seu valor esperado pode ser modelado por uma combinação linear de parâmetros desconhecidos. Seja y_i , $i = 1, \dots, n$ a variável resposta de um modelo de regressão, assumimos que y_i tem distribuição de Poisson com média λ_i , definida em função das covariáveis x_i . Assim, um modelo de regressão de Poisson é dado por

$$P(y_i) = \frac{e^{-\lambda_i} \lambda_i^{y_i}}{y_i!}$$

em que a esperança condicional é dado por $\lambda_i = E(y_i|x_i) = \exp(\mathbf{x}'_i \beta)$. O vetor $\mathbf{x}'_i = (x_{i,1}, x_{i,2}, \dots, x_{i,p})$ contem as covariáveis e $\beta' = (\beta_1, \dots, \beta_p)$ é o vetor de parâmetros do modelo de regressão.

A regressão de Poisson é inadequada quando temos excesso de zeros na amostra porque viola a suposição de equidispersão. Lambert (1992) introduziu o modelo de Poisson Inflacionado em Zero (ZIP) como uma alternativa na modelagem de dados deste tipo. Ele assume que as respostas provêm de dois processos. Um processo modela inflações em zero, incluindo uma proporção $1 - p$ de zeros extras e uma $p \exp(\lambda_i)$ de zeros da distribuição de Poisson; e o segundo modela as contagens diferentes de zero usando um modelos de Poisson trucado em zero. Assim, o modelo ZIP é dado por

$$P(Y_i = y_i | \mathbf{x}_i, z_i) = \begin{cases} \theta_i(z_i) + (1 - \theta_i(z_i)) \text{Pois}(\lambda_i; 0 | \mathbf{x}_i) & \text{se } y_i = 0 \\ (1 - \theta_i(z_i)) \text{Pois}(\lambda_i; y_i | \mathbf{x}_i) & \text{se } y_i > 0 \end{cases}$$

em que z_i é um vetor de covariáveis definindo a probabilidade θ_i . A média e variância do modelo são $(1 - \theta_i)\lambda_i$ e $(1 - \theta_i)(\lambda_i + \theta_i\lambda_i^2)$, respectivamente.

3 Aplicação

Os dados são provenientes de 250 acampamentos familiares em um parque nos Estados Unidos. Cada grupo foi questionado sobre o número de peixes capturados, quantas pessoas e quantas crianças o grupo tinha, e se eles foram acompanhados por um guia.

- **LIVE_BAIT:** Variável binária. Indica se foram usadas iscas vivas ou não;

- **CAMPER:** Variável binária. Indica se o grupo foi acompanhado por um guia ou não;
- **PERSONS:** Variável numérica. Número de pessoas no grupo;
- **CHILDREN:** Variável numérica. Número de crianças no grupo;
- **FISH_COUNT:** Variável numérica. Número de peixes pegos pelo grupo;

Pelo histograma da Figura 1, nota-se um número elevado de zeros, o que é um indicativo de que um modelo ZIP provavelmente se ajuste melhor aos dados.




Figura 1: Histograma de frequências do número de peixes capturados (variável resposta).

Utilizando o teste de superdispersão proposto por Cameron e Trivedi (1990), chegamos à conclusão de que existe superdispersão nos dados ($z \approx 1,8573$, $\alpha \approx 10,6243$, $p\text{-valor} \approx 0,03163$). Como a suposição de equidispersão não é satisfeita, não podemos ajustar um modelo de regressão de Poisson padrão. Pelos resultado do teste de superdispersão e com o gráfico da Figura 1, temos indícios que a superdispersão é causada pelo excesso de zeros na variável resposta (FISH_COUNT).

Ajustando um modelo ZIP com as variáveis covariáveis CHILDREN e CAMPER no modelo de contagem e PERSONS no modelo de zeros, chegamos aos resultados apresentados na Tabela 1. Os intervalos de confiança dos parâmetros foram calculados com base na normalidade assintótica destes e a estimação dos parâmetros foi feita através da maximização da função de log-verossimilhança usando o algoritmo EM, como descrito em Lambert (1992).

Tabela 1: Estimativas do modelo ZIP proposto.

Parametro	Estimativa	Erro padrão	Estatística do teste	p-valor	IC(95%)
Regressão de Poisson					
Intercepto	1,5979	0,0855	18,6804	< 0,0001	[1.4302 ; 1.7655]
CHILDREN	-1,0428	0,1000	-10,4296	< 0,0001	[-1.2388 ; -0.8469]
CAMPER (1)	0,8340	0,0936	8,9079	< 0,0001	[0.6505 ; 1.0175]
Regressão Logística					
Intercepto	1,2974	0,3739	3,4705	5e-04	[0.5647 ; 2.0302]
PERSONS	-0,5643	0,1630	-3,4630	5e-04	[-0.8838 ; -0.2449]

O parâmetro **CAMPER**(1) representa quando foi utilizado um guia. Como $e^{0,8340} = 2,30251$, podemos afirmar que, mantendo as demais variáveis fixas, a média de peixes capturados quando os visitantes do parque são acompanhados por um guia é aproximadamente 2,3 vezes maior do que quando não são.

Com a estimativa de **CHILDREN**, temos que o número de crianças afeta negativamente a média de peixes capturados. Mantendo as demais covariáveis fixas, o aumento em uma unidade no número de crianças representa um decréscimo na média de peixes capturados.

A estimativa do parâmetro **PERSONS** no modelo de regressão logística representa um decréscimo, $e^{-0,5643} = 0,5687$, no número de peixes capturados. Ou seja, para cada uma pessoa a mais no grupo, são capturados 0,5 vezes menos peixes.

Podemos ainda nos perguntar se o modelo ajustado realmente é superior à regressão padrão de Poisson. Comparando os dois ajustes com o teste de Vuong (Vuong (1989)) chegamos a um $p\text{-valor} \approx 0,00018$, evidenciando que o modelo ZIP é superior ao modelo de Poisson padrão.

Com o teste qui-quadrado, baseado no log das verossimilhanças, podemos testar a hipótese que o modelo ZIP ajustado é superior ao modelo somente com o intercepto. Com um $p\text{-valor} < 0,0001$, temos evidências para afirmar que o modelo ajustado é superior ao modelo somente com intercepto.

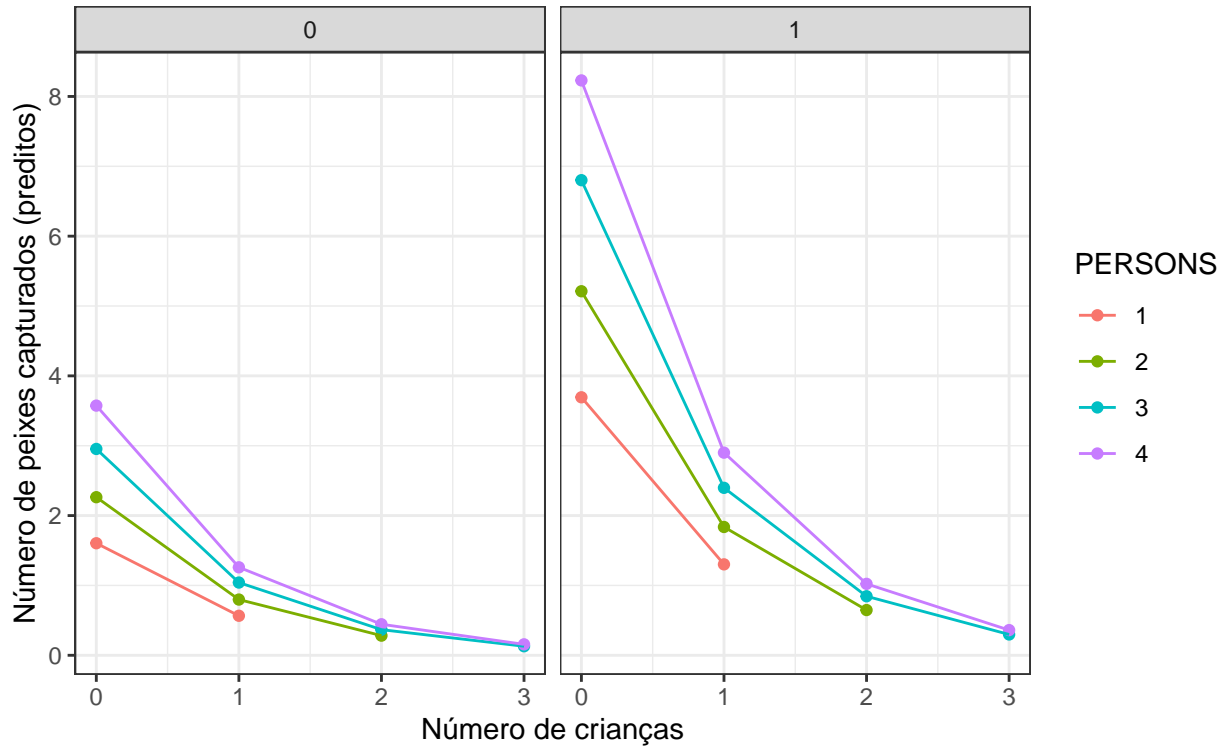


Figura 2: Predição usando o modelo ZIP. Usando um guia à direita e não usando à esquerda.

Na Figura 2 podemos ver como o modelo se comporta em termos de predição. À esquerda estão as predições para grupos que não usam guias e à direita para grupos que usam guias. Também podemos ver as diferenças causadas pelo número de pessoas e pelo número de crianças nos grupos.

4 Conclusões

A aplicação apresentada dá resultados condizentes com a metodologia descrita. Ao longo deste trabalho somos guiados pela base metodológica, chegando a resultados satisfatórios e podendo prever o número de peixes capturados com base nas covariáveis, enquanto acomodamos o excesso de zeros na variável resposta (número de peixes capturados).

A Figura 2 faz muito sentido prático, sendo compreensível que grupos com guias consigam mais capturas. Também faz sentido que grupos com crianças capturem menos peixes, já que elas acabam fazendo mais barulho perto da água. Por fim, quanto mais pessoas presentes no grupo, mais pescadores simultâneos e, portanto, mais capturas.

A melhor combinação para se capturar mais peixes parece ser, menos crianças, mais adultos e auxílio de um guia.

Referências

- Cameron, A. Colin, e Pravin K. Trivedi. 1990. “Regression-based tests for overdispersion in the Poisson model”. *Journal of Econometrics* 46 (3): 347–64. [https://doi.org/https://doi.org/10.1016/0304-4076\(90\)90014-K](https://doi.org/https://doi.org/10.1016/0304-4076(90)90014-K).
- Lambert, Diane. 1992. “Zero-inflated Poisson regression, with an application to defects in manufacturing”. *Technometrics* 34 (1): 1–14.
- R Core Team. 2021. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing. <https://www.R-project.org/>.
- Vuong, Quang H. 1989. “Likelihood ratio tests for model selection and non-nested hypotheses”. *Econometrica: Journal of the Econometric Society*, 307–33.